

SAP MM Support Assistant

Riscos, Limitações e Próximos Passos

1. Riscos

1.1 Alucinação do LLM

O modelo pode gerar orientações incorretas em casos muito específicos não cobertos pela base de conhecimento. O prompt instrui o agente a responder apenas com base no RAG e a indicar nível de confiança BAIXO quando não encontrar informação suficiente.

1.2 Base de Conhecimento Desatualizada

Se os processos SAP do cliente mudarem e o manual não for atualizado no Pinecone, o assistente continuará respondendo com informações antigas. Mitigação: processo periódico de atualização da base de conhecimento.

1.3 Chamados Ambíguos

Usuários que descrevem o problema de forma vaga podem receber respostas inadequadas ou entrar em loop de solicitação de informações. O campo solicitar_mais_informacoes trata esse cenário, mas depende da qualidade da resposta do usuário.

1.4 Falha no Envio de Email

Se o serviço de email falhar em um caso crítico, o gestor não recebe a notificação de aprovação. Em produção, implementar retry automático e canal de fallback como notificação via Teams ou WhatsApp.

1.5 Custo de Tokens

Chamados complexos com contexto grande podem consumir muitos tokens da OpenAI. Em alto volume, o custo pode ser relevante. Mitigação: monitorar uso e otimizar o tamanho do contexto enviado ao LLM.

2. Limitações

2.1 Escopo Limitado ao SAP MM

O assistente foi desenvolvido com documentação do módulo MM. Chamados de outros módulos como FI, SD, PP e Basis são redirecionados mas não respondidos com orientações técnicas específicas.

2.2 Sem Acesso a Dados Reais do SAP

O protótipo não se conecta ao SAP real. Em produção seria necessária integração via OData/BTP para buscar dados contextuais como status real do pedido, estoque atual e histórico de movimentos.

2.3 Sem Memória entre Chamados

Cada chamado é tratado de forma independente. O assistente não reconhece chamados anteriores do mesmo usuário ou problemas recorrentes sobre o mesmo tema.

2.4 Interface Limitada ao Postman

O protótipo simula a entrada via API. Em produção seria necessária integração nativa com a plataforma de tickets do cliente como Freshdesk, ServiceNow ou Jira.

2.5 Volume Não Testado

O protótipo foi validado com 5 chamados sequenciais. Comportamento sob alto volume simultâneo não foi avaliado nesta fase.

3. Próximos Passos

Curto Prazo

- Expandir a base de conhecimento para outros módulos SAP — FI, SD, Basis
- Integrar com SAP via OData APIs para enriquecer o contexto com dados reais
- Implementar retry automático de email em casos críticos
- Adicionar canal de notificação alternativo como Teams ou WhatsApp

Médio Prazo

- Feedback loop — consultor avalia a resposta e o resultado retroalimenta a base de conhecimento
- Dashboard de métricas — volume de chamados, taxa de automação e nível de confiança médio
- Memória de chamados anteriores por usuário — assistente reconhece problemas recorrentes
- Integração nativa com plataformas de tickets como Freshdesk, ServiceNow e Jira